Abstract of CN116682018A

The invention discloses a vehicle track prediction method, device and system and a storage medium, and belongs to the technical field of automatic driving, and the method comprises the steps: constructing a vectorization map, and constructing an urban road network structure through the vectorization map; capturing complex road information and continuous vehicle track information according to the urban road network structure; according to the complex road information and the continuous vehicle track information, multi-line-level features are obtained through calculation; constructing a global graph model according to the multi-line-level features; and according to the global graph model, decoding a target node by using a recurrent neural network decoder to obtain a vehicle trajectory prediction result. According to the method, complex road information and continuous vehicle track information can be extracted with high quality, so that the vehicle track prediction precision is improved.

(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 116682018 A
(43)申请公布日 2023.09.01

(21)申请号 202310793980.4

(22)申请日 2023.06.30

(71)申请人 南京邮电大学
地址 210023 江苏省南京市栖霞区文苑路9号

(72)发明人 徐小龙 施秋豪 王勇 陈鹏宇

(74)专利代理机构 南京纵横知识产权代理有限公司 32224
专利代理师 钱玲玲

(51)Int.Cl.
G06V 20/10(2022.01)
G06V 20/54(2022.01)
G06V 10/82(2022.01)
G06N 3/0442(2023.01)
G06N 3/0464(2023.01)

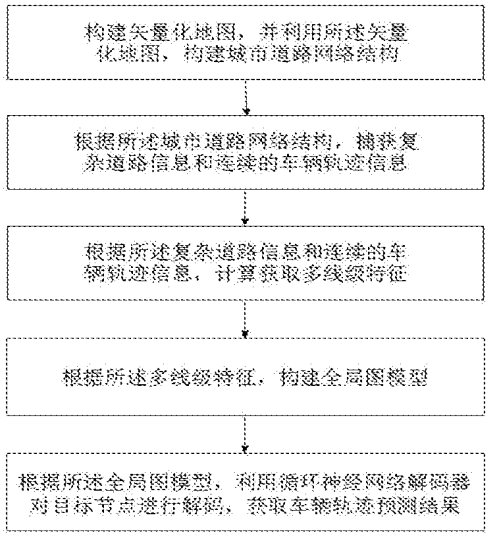
权利要求书3页 说明书11页 附图4页

(54)发明名称

一种车辆轨迹预测方法、装置、系统及存储介质

(57)摘要

本发明公开了一种车辆轨迹预测方法、装置、系统及存储介质，属于自动驾驶技术领域，方法包括：构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构；根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；根据所述多线级特征，构建全局图模型；根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果。该方法能够高质量地提取复杂道路信息和连续的车辆轨迹信息，以提高车辆轨迹预测精度。



CN 116682018 A

1.一种车辆轨迹预测方法，其特征在于，包括：

构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构；

根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；

根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；

根据所述多线级特征，构建全局图模型；

根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果。

2.根据权利要求1所述的车辆轨迹预测方法，其特征在于，构建矢量化地图包括：

对线路进行采样，获取采样点；

将所述采样点连接形成折线；

对所述折线进行向量化，获取向量集；

将所述向量集中的向量作为节点，通过所述节点的连接，在所述向量集上构成矢量化地图；

其中，所述线路包括车辆轨迹和城市道路；

所述节点的表达式如公式(1)所示：

$$v=[d^s,d^e,a,r] \quad (1)$$

公式(1)中，v为节点v，即向量集中的向量v，d^s为向量v的起始点坐标，d^e为向量v的结束点坐标，a为向量v对应的属性特征，r为向量v所属折线的整数ID。

3.根据权利要求1所述的车辆轨迹预测方法，其特征在于，利用所述矢量化地图，构建城市道路网络结构包括：

根据所述矢量化地图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵，构建城市道路网络结构；

其中，所述特征矩阵由各节点的属性特征构成，所述属性特征包括：车辆轨迹的时间戳、城市道路的特征类型和车道速度限制；

所述邻接矩阵的表达式如公式(2)所示：

$$A=\{A_{m,j,k}\}_{m\in\{pre,suc,left,right\}} \quad (2)$$

公式(2)中，A为邻接矩阵，k为第k个节点，j为第j个节点，m为第k个节点和第j个节点之间的关系索引，pre、suc、left、right为前任、后继、左邻、右邻关系，$A_{m,j,k}$为第k个节点和第j个节点之间的连通性变量，$A_{m,j,k}=1$表示第k个节点是第j个节点的m型关系，$A_{m,j,k}=0$表示第k个节点非第j个节点的m型关系，其中，对于任意节点，将其前任节点定义为能够前往该节点的相邻节点，将其后继节点定义为能够从该节点出发的相邻节点，将其左邻、右邻节点定义为该节点左、右最接近的节点。

4.根据权利要求1所述的车辆轨迹预测方法，其特征在于，根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息包括：

将所述城市道路网络结构中属于同一折线的所有节点彼此连接，在向量级构建子图；

根据所述子图，利用预获取的扩展图卷积网络，捕获复杂道路信息；

根据所述子图，利用预获取的循环神经网络，捕获连续的车辆轨迹信息；

其中，利用预获取的扩展图卷积网络，捕获复杂道路信息包括：

在傅里叶域中构建作用于所述子图中各节点的滤波器；

对所述子图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵进行卷积处理，利用所述滤波器，捕获所述子图中各节点周围的复杂道路信息；

所述复杂道路信息的表达式如公式(3)所示：

$$Y = \hat{D}^{-\frac{1}{2}}\hat{A}\hat{D}^{-\frac{1}{2}}XW \quad (3)$$

公式(3)中，Y为滤波器的输出，即复杂道路信息，X为特征矩阵，A为邻接矩阵，$\hat{A} = A + I$，I为单位矩阵，$\hat{D}$为$\hat{A}$的度矩阵，$\hat{D}^{-\frac{1}{2}}\hat{A}\hat{D}^{-\frac{1}{2}}$为对邻接矩阵A进行对称归一化处理，W为权矩阵；

所述连续的车辆轨迹信息的时间特征的表达式如公式(4)所示：

$$\begin{cases} O_t = V \cdot S_t \\ S_t = f(U \cdot P_t + B \cdot S_{t-1}) \end{cases} \quad (4)$$

公式(4)中，t为t时刻，O_t为t时刻循环神经网络的输出，P_t为t时刻循环神经网络的输入，S_t为t时刻循环神经网络的隐藏值，S_{t-1}为t-1时刻循环神经网络的隐藏值，V为循环神经网络中隐藏层到输出层的参数矩阵，U为循环神经网络中输入层到隐藏层的参数矩阵，B为每个时间点之间的权重矩阵，f为循环递归公式。

5.根据权利要求4所述的车辆轨迹预测方法，其特征在于，根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征包括：

对于所述子图中的折线及其节点，定义单层子图传播操作；

根据所述单层子图传播操作，将所述复杂道路信息和连续的车辆轨迹信息输入至所述子图，并由所述子图中各节点计算获取多线级特征；

其中，所述单层子图传播操作的表达式如公式(5)所示：

$$v^{(l+1)} = \varphi_{rel}\left(g_{enc}\left(v^{(l)}\right), \varphi_{con}\left(u^{(l)}\right)\right) \quad (5)$$

公式(5)中，v为节点v，$v^{(l+1)}$为节点v的第l+1层节点特征，$v^{(l)}$为节点v的第l层节点特征，$u^{(l)}$为节点v附近的节点，$g_{enc}(\cdot)$为使循环神经网络对单个节点特征进行交换，$\varphi_{con}(\cdot)$为利用扩展图卷积网络对所有相邻节点进行信息聚合，$\varphi_{rel}(\cdot)$为节点v与其相邻接点之间的简单连接；

所述多线级特征的计算公式如公式(6)所示：

$$L_v = \varphi_{agg}\left(v^{(l)}\right) \quad (6)$$

公式(6)中，L_v为节点v的多线级特征，$\varphi_{agg}(\cdot)$为最大池化操作。

6.根据权利要求4所述的车辆轨迹预测方法，其特征在于，根据所述多线级特征，构建全局图模型包括：

根据所述多线级特征，利用预获取的图神经网络和自注意力机制，对所述子图中属于同一折线的所有节点的节点特征进行高阶交互建模，获取全局图模型；

其中，所述全局图模型的表达式如公式(7)所示：

$$\begin{cases} \left\{L_{vn}^{(l+1)}\right\} = GNN\left(\left\{L_{vn}^{(l)}\right\}, \mathcal{A}\right) \\ GNN(\mathcal{X}) = softmax\left(\mathcal{X}_Q \mathcal{X}_K^T\right)\mathcal{X}_V \end{cases} \quad (7)$$

公式(7)中，$L_{vn}^{(l+1)}$为属于同一折线的第n个节点v的多线级特征经过l+1层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l+1)}\right\}$为属于同一折线的节点的第l+1层多线级节点特征集，$L_{vn}^{(l)}$为属于同一折线的第n个节点v的多线级特征经过l层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l)}\right\}$为属于同一折线的节点的第l层多线级节点特征集，$\mathcal{A}$为对应属于同一折线的节点集的邻接矩阵，$\mathcal{A}$为一个全连通图，$\mathcal{X}$为经过多线级特征提取后的节点的特征矩阵，$\mathcal{X}_Q$、$\mathcal{X}_K$、$\mathcal{X}_V$均为经过多线级特征提取后的节点的特征矩阵$\mathcal{X}$的线性投影，GNN(•)为单层的图神经网络。

7.根据权利要求1所述的车辆轨迹预测方法，其特征在于，利用循环神经网络解码器对目标节点进行解码的公式如公式(8)所示：

$$v^{future} = \varphi_{traj}\left(L_v^{(\mathcal{L})}\right) \quad (8)$$

公式(8)中，v^{future}为节点v的车辆轨迹预测结果，L_v为节点v的多线级特征，$\mathcal{L}$为图神经网络总层数，$L_v^{(\mathcal{L})}$为节点v的多线级特征L_v经过全部层图神经网络传递后得到的特征，$\varphi_{traj}(\cdot)$为循环神经网络解码器。

8.一种车辆轨迹预测装置，其特征在于，包括：

网络构建模块：用于构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构；

信息捕获模块：用于根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；

多线级特征计算模块：用于根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；

全局图模型构建模块：用于根据所述多线级特征，构建全局图模型；

预测模块：用于根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果。

9.一种系统，其特征在于，包括处理器及存储介质；

所述存储介质用于存储指令；

所述处理器用于根据所述指令进行操作以执行根据权利要求1～7任一项所述方法的步骤。

10.一种计算机可读存储介质，其上存储有计算机程序，其特征在于，该程序被处理器执行时实现权利要求1～7任一项所述方法的步骤。

一种车辆轨迹预测方法、装置、系统及存储介质

技术领域

[0001] 本发明涉及一种车辆轨迹预测方法、装置、系统及存储介质，属于自动驾驶技术领域。

背景技术

[0002] 自动驾驶越来越受到学术界和工业界的关注，因为它在解决安全、拥堵、节能等许多长期交通挑战方面有很大的潜力。近年来，我们见证了自动驾驶汽车的感知、规划和控制系统的快速发展。但是，只有自动驾驶的安全性得到验证，才能实现量产。为了进一步提高安全性，最关键的技术之一是自动驾驶汽车应该能够像人类驾驶员一样实时预测周围车辆轨迹以便做出判断。

[0003] 当人驾驶车辆时，通常会观察周围的交通参与者并预测他们未来的状态，然后再开始新的驾驶动机。未来轨迹可以表示交通参与者的未来状态，用于提前检测潜在危险，并用于设计决策或规划算法。然而，由于交通参与者的动机多样、交通参与者与环境的复杂交互作用、感官信息的不确定性、自动驾驶汽车的计算负担和计算时间要求，如何准确预测交通参与者的未来轨迹备受关注，成为提高自动驾驶安全性的关键点之一。

[0004] 近年来基于深度学习的流量预测方法通过训练网络使得模型具有自主学习特征，使得车辆轨迹预测性能大幅度提升，其中包括：基于卷积社交池的长短期记忆网络的CS-LSTM(M)模型，基于注意力机制的长短期记忆网络的MHA-LSTM模型等；基于向量化网络的VectorNet模型，基于图的信息共享网络GISNet模型等。然而，地图是具有复杂拓扑结构的图结构，栅格化过程不可避免地会导致信息丢失。此外，尽管两对车道在空间上彼此接近，相同或相反方向的车道对具有完全不同的语义含义和依赖关系。而且，为了获取长距离的车道信息，接受域有时不仅要覆盖预期区域，还要覆盖车道外的大片区域。因此车辆轨迹预测仍是一个具有挑战的任务，现有的车辆轨迹预测方法在预测精度以及稳定性方面仍有上升空间。

发明内容

[0005] 本发明的目的在于提供一种车辆轨迹预测方法、装置、系统及存储介质，能够高质量地提取复杂道路信息和连续的车辆轨迹信息，以提高车辆轨迹预测精度。

[0006] 为达到上述目的，本发明提供如下技术方案：

[0007] 第一方面，本发明提供一种车辆轨迹预测方法，包括：

[0008] 构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构；

[0009] 根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；

[0010] 根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；

[0011] 根据所述多线级特征，构建全局图模型；

[0012] 根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果。

[0013] 结合第一方面，进一步的，构建矢量化地图包括：

[0014] 对线路进行采样，获取采样点；

[0015] 将所述采样点连接形成折线；

[0016] 对所述折线进行向量化，获取向量集；

[0017] 将所述向量集中的向量作为节点，通过所述节点的连接，在所述向量集上构成矢量化地图；

[0018] 其中，所述线路包括车辆轨迹和城市道路；

[0019] 所述节点的表达式如公式(1)所示：

[0020] $v=[d^s,d^e,a,r]$ (1)

[0021] 公式(1)中，v为节点v，即向量集中的向量v，d^s为向量v的起始点坐标，d^e为向量v的结束点坐标，a为向量v对应的属性特征，r为向量v所属折线的整数ID。

[0022] 结合第一方面，进一步的，利用所述矢量化地图，构建城市道路网络结构包括：

[0023] 根据所述矢量化地图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵，构建城市道路网络结构；

[0024] 其中，所述特征矩阵由各节点的属性特征构成，所述属性特征包括：车辆轨迹的时间戳、城市道路的特征类型和车道速度限制；

[0025] 所述邻接矩阵的表达式如公式(2)所示：

[0026] $A=\{A_{m,j,k}\}_{m\in\{pre,suc,left,rig\ ht\}}$ (2)

[0027] 公式(2)中，A为邻接矩阵，k为第k个节点，j为第j个节点，m为第k个节点和第j个节点之间的关系索引，pre、suc、left、right为前任、后继、左邻、右邻关系，$A_{m,j,k}$为第k个节点和第j个节点之间的连通性变量，$A_{m,j,k}=1$表示第k个节点是第j个节点的m型关系，$A_{m,j,k}=0$表示第k个节点非第j个节点的m型关系，其中，对于任意节点，将其前任节点定义为能够前往该节点的相邻节点，将其后继节点定义为能够从该节点出发的相邻节点，将其左邻、右邻节点定义为该节点左、右最接近的节点。

[0028] 结合第一方面，进一步的，根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息包括：

[0029] 将所述城市道路网络结构中属于同一折线的所有节点彼此连接，在向量级构建子图；

[0030] 根据所述子图，利用预获取的扩展图卷积网络，捕获复杂道路信息；

[0031] 根据所述子图，利用预获取的循环神经网络，捕获连续的车辆轨迹信息；

[0032] 其中，利用预获取的扩展图卷积网络，捕获复杂道路信息包括：

[0033] 在傅里叶域中构建作用于所述子图中各节点的滤波器；

[0034] 对所述子图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵进行卷积处理，利用所述滤波器，捕获所述子图中各节点周围的复杂道路信息；

[0035] 所述复杂道路信息的表达式如公式(3)所示：

[0036] $$Y=\widehat{D}^{-\frac{1}{2}}\hat{A}\widehat{D}^{-\frac{1}{2}}XW \quad (3)$$

[0037] 公式(3)中，Y为滤波器的输出，即复杂道路信息，X为特征矩阵，A为邻接矩阵，$\hat{A}=A+I$，I为单位矩阵，$\widehat{D}$为$\hat{A}$的度矩阵，$\widehat{D}^{-\frac{1}{2}}\hat{A}\widehat{D}^{-\frac{1}{2}}$为对邻接矩阵A进行对称归一化处

理，W为权矩阵；

[0038] 所述连续的车辆轨迹信息的时间特征的表达式如公式(4)所示：

[0039] $$\begin{cases} O_t = V \cdot S_t \\ S_t = f(U \cdot P_t + B \cdot S_{t-1}) \end{cases} \quad (4)$$

[0040] 公式(4)中，t为t时刻，O_t为t时刻循环神经网络的输出，P_t为t时刻循环神经网络的输入，S_t为t时刻循环神经网络的隐藏值，S_{t-1}为t-1时刻循环神经网络的隐藏值，V为循环神经网络中隐藏层到输出层的参数矩阵，U为循环神经网络中输入层到隐藏层的参数矩阵，B为每个时间点之间的权重矩阵，f为循环递归公式。

[0041] 结合第一方面，进一步的，根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征包括：

[0042] 对于所述子图中的折线及其节点，定义单层子图传播操作；

[0043] 根据所述单层子图传播操作，将所述复杂道路信息和连续的车辆轨迹信息输入至所述子图，并由所述子图中各节点计算获取多线级特征；

[0044] 其中，所述单层子图传播操作的表达式如公式(5)所示：

[0045] $$v^{(l+1)} = \varphi_{rel}\left(g_{enc}\left(v^{(l)}\right), \varphi_{con}\left(u^{(l)}\right)\right) \quad (5)$$

[0046] 公式(5)中，v为节点v，$v^{(l+1)}$为节点v的第l+1层节点特征，$v^{(l)}$为节点v的第l层节点特征，$u^{(l)}$为节点v附近的节点，$g_{enc}(\cdot)$为使循环神经网络对单个节点特征进行交换，$\varphi_{con}(\cdot)$为利用扩展图卷积网络对所有相邻节点进行信息聚合，$\varphi_{rel}(\cdot)$为节点v与其相邻接点之间的简单连接；

[0047] 所述多线级特征的计算公式如公式(6)所示：

[0048] $$L_v = \varphi_{agg}\left(v^{(l)}\right) \quad (6)$$

[0049] 公式(6)中，L_v为节点v的多线级特征，$\varphi_{agg}(\cdot)$为最大池化操作。

[0050] 结合第一方面，进一步的，根据所述多线级特征，构建全局图模型包括：

[0051] 根据所述多线级特征，利用预获取的图神经网络和自注意力机制，对所述子图中属于同一折线的所有节点的节点特征进行高阶交互建模，获取全局图模型；

[0052] 其中，所述全局图模型的表达式如公式(7)所示：

[0053] $$\begin{cases} \left\{L_{vn}^{(l+1)}\right\} = GNN\left(\left\{L_{vn}^{(l)}\right\}, \mathcal{A}\right) \\ GNN(\mathcal{X}) = softmax\left(\mathcal{X}_Q \mathcal{X}_K^T\right)\mathcal{X}_V \end{cases} \quad (7)$$

[0054] 公式(7)中，$L_{vn}^{(l+1)}$为属于同一折线的第n个节点v的多线级特征经过l+1层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l+1)}\right\}$为属于同一折线的节点的第l+1层多线级节点特征集，$L_{vn}^{(l)}$为属于同一折线的第n个节点v的多线级特征经过l层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l)}\right\}$为属于同一折线的节点的第l层多线级节点特征集，$\mathcal{A}$为对应属于同一折线的节点集的邻接矩阵，$\mathcal{A}$为一个全连通图，$\mathcal{X}$为经过多线级特征提取后的节点的特征

矩阵，$\mathcal{X}_Q$、$\mathcal{X}_K$、$\mathcal{X}_V$均为经过多线级特征提取后的节点的特征矩阵$\mathcal{X}$的线性投影，GNN（•）为单层的图神经网络。

[0055] 结合第一方面，进一步的，利用循环神经网络解码器对目标节点进行解码的公式如公式(8)所示：

[0056] $$v^{future} = \varphi_{traj}\left(L_v^{(\mathcal{L})}\right) \quad (8)$$

[0057] 公式(8)中，v^{future}为节点v的车辆轨迹预测结果，L_v为节点v的多线级特征，$\mathcal{L}$为图神经网络总层数，$L_v^{(\mathcal{L})}$为节点v的多线级特征L_v经过全部层图神经网络传递后得到的特征，$\varphi_{traj}(\cdot)$为循环神经网络解码器。

[0058] 第二方面，本发明提供一种车辆轨迹预测装置，包括：

[0059] 网络构建模块：用于构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构；

[0060] 信息捕获模块：用于根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；

[0061] 多线级特征计算模块：用于根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；

[0062] 全局图模型构建模块：用于根据所述多线级特征，构建全局图模型；

[0063] 预测模块：用于根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果。

[0064] 第三方面，本发明提供一种系统，包括处理器及存储介质；

[0065] 所述存储介质用于存储指令；

[0066] 所述处理器用于根据所述指令进行操作以执行根据第一方面任一项所述方法的步骤。

[0067] 第四方面，本发明提供一种计算机可读存储介质，其上存储有计算机程序，该程序被处理器执行时实现第一方面任一项所述方法的步骤。

[0068] 与现有技术相比，本发明的有益效果是：

[0069] 本发明提供的车辆轨迹预测方法，使用了一种新的地图交互，直接对原始地图进行矢量化来构建地图，能够避免信息丢失；对复杂道路信息和连续的车辆轨迹信息进行高质量提取，并计算多线级特征，从而构建全局图模型进行车辆轨迹预测，能够提高车辆轨迹预测精度。利用扩展图卷积网络对特征矩阵和邻接矩阵进行卷积处理，能够捕获具有复杂拓扑结构的车道特征以及空间依赖关系，从而获取复杂道路信息；因为车辆轨迹信息是时间上连续的序列，因此利用循环神经网络捕捉车辆轨迹特征，以此获取车辆轨迹动态变化信息，结合复杂道路信息实现更高精度地预测；构建层次化的图网络，将局部子图中由扩展图卷积网络和循环神经网络获取的特征信息传递到全局图，运用自注意力机制进行车道与车道、车道与车辆以及车辆与车辆的高阶交互，进而实现高准确度、高稳定度的轨迹预测。

附图说明

[0070] 图1是本发明实施例提供的车辆轨迹预测方法流程图；

[0071] 图2是本发明实施例提供的车辆轨迹预测的整体架构示意图；

[0072] 图3是本发明实施例提供的利用扩展图卷积网络捕获复杂道路信息的示意图，其中，(a)为复杂道路节点的扩展图卷积过程示意图，(b)为扩展图卷积网络结构示意图；

[0073] 图4是本发明实施例提供的全局图模型示意图；

[0074] 图5是本发明实施例提供的在Argoverse数据集上平均位移误差ADE和最终位移误差FDE的比较结果示意图；

[0075] 图6是本发明实施例提供的在NGSIM I-80数据集上均方根误差RMSE的比较结果示意图。

具体实施方式

[0076] 下面结合具体实施方式对本申请的技术方案作进一步详细地说明。

[0077] 下面详细描述本申请的实施例，实施例的示例在附图中示出，其中自始至终相同或类似的标号表示相同或类似的元件或具有相同或类似功能的元件。下面通过参考附图描述的实施例是示例性的，仅用于解释本申请，而不能理解为对本申请的限制。在不冲突的情况下，本申请实施例以及实施例中的技术特征可以相互组合。

[0078] 实施例一：

[0079] 图1是本发明实施例一提供的一种车辆轨迹预测方法流程图，本流程图仅仅示出了本实施例方法的逻辑顺序，在互不冲突的前提下，在本发明其它可能的实施例中，可以以不同于图1所示的顺序完成所示出或描述的步骤。

[0080] 本实施例提供的车辆轨迹预测方法可应用于终端，可以由车辆轨迹预测装置来执行，该装置可以由软件和/或硬件的方式实现，该装置可以集成在终端中，例如：任一具备通信功能的平板电脑或计算机设备。参见图1，本实施例的方法具体包括如下步骤：

[0081] 步骤一：构建矢量化地图，并利用矢量化地图，构建城市道路网络结构；

[0082] 矢量化地图是由车辆轨迹、城市道路等向量化表示构成的地图。车辆轨迹是关于时间的有向样条形式，可以近似为向量序列，对于车辆轨迹，我们可以用固定的时间间隔对车辆行驶轨迹中的点进行采样，并将它们连接到向量中。给定足够小的空间或时间间隔，产生的折线可以作为原始地图和车辆轨迹的近似值。向量化过程是连续轨迹、映射注释和向量集之间的一对一映射，这允许我们在向量集之上形成一个图表示，可以用图神经网络进行编码，具体地说，我们将属于地图折线的每个向量视为图中的一个节点，节点以向量的形式表述车辆轨迹、城市道路，我们将向量视为图中的一个节点，通过节点的连接在向量集上形成矢量化地图。

[0083] 构建矢量化地图包括如下步骤：

[0084] 步骤①：对线路进行采样，获取采样点；

[0085] 本实施例中，线路包括车辆轨迹和城市道路。

[0086] 步骤②：将采样点连接形成折线；

[0087] 步骤③：对折线进行向量化，获取向量集；

[0088] 步骤④：将向量集中的向量作为节点，通过节点的连接，在向量集上构成矢量化地图。

[0089] 其中，节点的表达式如公式(1)所示：

[0090] $v=[d^s,d^e,a,r]$ (1)

[0091] 公式(1)中，v为节点v，即向量集中的向量v，d^s为向量v的起始点坐标，d^e为向量v的结束点坐标，a为向量v对应的属性特征，r为向量v所属折线的整数ID。

[0092] 形成的矢量化地图中的每个节点都包含着丰富的属性特征，如车辆轨迹的时间戳、城市道路的特征类型和车道速度限制等，这有助于我们在图的形式中通过获取节点的属性特征以及节点之间的联系来构建城市道路网络结构。

[0093] 利用矢量化地图，构建城市道路网络结构包括：根据矢量化地图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵，构建城市道路网络结构。

[0094] 其中，特征矩阵由各节点的属性特征构成，本实施例中，属性特征包括：车辆轨迹的时间戳、城市道路的特征类型和车道速度限制。

[0095] 邻接矩阵的表达式如公式(2)所示：

[0096] $$A=\{A_{m,j,k}\}_{m\in\{pre,suc,left,rig\ ht\}} \quad (2)$$

[0097] 公式(2)中，A为邻接矩阵，k为第k个节点，j为第j个节点，m为第k个节点和第j个节点之间的关系索引，pre、suc、left、right为前任、后继、左邻、右邻关系，$A_{m,j,k}$为第k个节点和第j个节点之间的连通性变量，$A_{m,j,k}=1$表示第k个节点是第j个节点的m型关系，$A_{m,j,k}=0$表示第k个节点非第j个节点的m型关系，其中，对于任意节点，将其前任节点定义为能够前往该节点的节点，将其后继节点定义为能够从该节点出发的节点，将其左邻、右邻节点定义为该节点左、右最接近的节点，即空间上最接近的节点，分别由左、右相邻车道上的距离测量。

[0098] 邻接矩阵从连通性的角度进一步完善了城市道路网络结构，有助于后续扩展图卷积网络利用城市道路网络结构进行复杂道路信息的捕获。

[0099] 步骤二：根据城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息；

[0100] 在构建城市道路网络结构之后，为了利用节点的空间和语义局部性，采用一种分层方法，将属于同一折线的所有节点彼此连接，在向量级构建子图。复杂道路信息包括会影响到车辆轨迹的道路特征类型、车道速度限制、车道之间的连通性等一系列信息。普通的图卷积网络只能捕获节点邻接部分的空间特征，而扩展图卷积网络可以利用4个邻接矩阵捕获范围更广的进一步关系。如图3所示，为本实施例提供的利用扩展图卷积网络捕获复杂道路信息的示意图，其中，(a)为复杂道路节点的扩展图卷积过程示意图，(b)为扩展图卷积网络结构示意图，(b)中，每个卷积模块由一个扩展图卷积(1,2,4,8,16,32)和一个带有残差连接的线性层组成，所有层有128个特征通道。基于车道具有复杂的拓扑结构，利用扩展图卷积网络对城市道路网络结构中的邻接矩阵和由节点属性特征构成的特征矩阵进行卷积处理来获取空间信息，具体操作为在傅里叶域中构造一个作用于节点的滤波器，捕获该节点周围的复杂道路信息。因为车辆轨迹信息是时间上连续的序列，因此利用循环神经网络捕获车辆轨迹信息的时间特征。

[0101] 根据城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息包括如下步骤：

[0102] 步骤A：将城市道路网络结构中属于同一折线的所有节点彼此连接，在向量级构建子图；

[0103] 步骤B：根据子图，利用预获取的扩展图卷积网络，捕获复杂道路信息；

[0104] 利用预获取的扩展图卷积网络，捕获复杂道路信息包括如下步骤：

[0105] 步骤i：在傅里叶域中构建作用于子图中各节点的滤波器；

[0106] 步骤ii：对子图中各节点的特征矩阵和表示各节点之间连通性的邻接矩阵进行卷积处理，利用滤波器，捕获子图中各节点周围的复杂道路信息；

[0107] 复杂道路信息的表达式如公式(3)所示：

[0108] $$Y = \widehat{D}^{-\frac{1}{2}}\hat{A}\widehat{D}^{-\frac{1}{2}}XW \quad (3)$$

[0109] 公式(3)中，Y为滤波器的输出，即复杂道路信息，X为特征矩阵，A为邻接矩阵，$\hat{A} = A + I$，I为单位矩阵，$\widehat{D}$为$\hat{A}$的度矩阵，$\widehat{D}^{-\frac{1}{2}}\hat{A}\widehat{D}^{-\frac{1}{2}}$为对邻接矩阵A进行对称归一化处理，W为权矩阵，本实施例中，所有连接共享相同的权重。

[0110] 步骤C：根据子图，利用预获取的循环神经网络，捕获连续的车辆轨迹信息；

[0111] 连续的车辆轨迹信息的时间特征的表达式如公式(4)所示：

[0112] $$\begin{cases} O_t = V \cdot S_t \\ S_t = f(U \cdot P_t + B \cdot S_{t-1}) \end{cases} \quad (4)$$

[0113] 公式(4)中，t为t时刻，O_t为t时刻循环神经网络的输出，P_t为t时刻循环神经网络的输入，S_t为t时刻循环神经网络的隐藏值，S_{t-1}为t-1时刻循环神经网络的隐藏值，V为循环神经网络中隐藏层到输出层的参数矩阵，U为循环神经网络中输入层到隐藏层的参数矩阵，B为每个时间点之间的权重矩阵，f为循环递归公式，代表隐藏值的不断传递。

[0114] 步骤三：根据复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征；

[0115] 由于节点的彼此连接，将步骤二中提取的复杂道路信息和连续的车辆轨迹信息输入到子图中，由子图中的节点通过计算获取多线级特征，多线级特征包括了从复杂道路信息和连续的车辆轨迹信息中提取的多个特征。

[0116] 根据复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征包括如下步骤：

[0117] 步骤a：对于子图中的折线及其节点，定义单层子图传播操作；

[0118] 单层子图传播操作的表达式如公式(5)所示：

[0119] $$v^{(l+1)} = \varphi_{rel}\left(g_{enc}\left(v^{(l)}\right), \varphi_{con}\left(u^{(l)}\right)\right) \quad (5)$$

[0120] 公式(5)中，v为节点v，$v^{(l+1)}$为节点v的第l+1层节点特征，$v^{(l)}$为节点v的第l层节点特征，$u^{(l)}$为节点v附近的节点，$g_{enc}(\cdot)$为使循环神经网络对单个节点特征进行交换，$\varphi_{con}(\cdot)$为利用扩展图卷积网络对所有相邻节点进行信息聚合，$\varphi_{rel}(\cdot)$为节点v与其相邻接点之间的简单连接。

[0121] 步骤b：根据单层子图传播操作，将复杂道路信息和连续的车辆轨迹信息输入至子图，并由子图中各节点计算获取多线级特征；

[0122] 多线级特征的计算公式如公式(6)所示：

[0123] $$L_v = \varphi_{agg}\left(v^{(l)}\right) \quad (6)$$

[0124] 公式(6)中，L_v为节点v的多线级特征，$\varphi_{agg}(\cdot)$为最大池化操作。

[0125] 步骤四：根据多线级特征，构建全局图模型；

[0126] 本实施例中，根据多线级特征，构建全局图模型时，根据多线级特征，利用预获取的图神经网络和自注意力机制，对子图中属于同一折线的所有节点的节点特征进行高阶交互建模，获取全局图模型。

[0127] 其中，全局图模型的表达式如公式(7)所示：

[0128] $$\begin{cases} \left\{L_{vn}^{(l+1)}\right\} = GNN\left(\left\{L_{vn}^{(l)}\right\}, \mathcal{A}\right) \\ GNN(\mathcal{X}) = softmax\left(\mathcal{X}_Q \mathcal{X}_K^T\right)\mathcal{X}_V \end{cases} \quad (7)$$

[0129] 公式(7)中，$L_{vn}^{(l+1)}$为属于同一折线的第n个节点v的多线级特征经过l+1层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l+1)}\right\}$为属于同一折线的节点的第l+1层多线级节点特征集，$L_{vn}^{(l)}$为属于同一折线的第n个节点v的多线级特征经过l层图神经网络传递后的多线级节点特征，$\left\{L_{vn}^{(l)}\right\}$为属于同一折线的节点的第l层多线级节点特征集，$\mathcal{A}$为对应属于同一折线的节点集的邻接矩阵，$\mathcal{A}$为一个全连通图，$\mathcal{X}$为经过多线级特征提取后的节点的特征矩阵，$\mathcal{X}_Q$、$\mathcal{X}_K$、$\mathcal{X}_V$均为经过多线级特征提取后的节点的特征矩阵$\mathcal{X}$的线性投影，GNN(•)为单层的图神经网络。

[0130] 如图4所示，为本实施例提供的全局图模型示意图，通过构建层次化的图网络，将局部子图中由扩展图卷积网络和循环神经网络获取的特征信息传递到全局图，运用自注意力机制进行车道与车道、车道与车辆以及车辆与车辆的高阶交互，进而实现高准确度、高稳定度的轨迹预测。

[0131] 步骤五：根据全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果；

[0132] 利用循环神经网络解码器对目标节点进行解码的公式如公式(8)所示：

[0133] $$v^{future} = \varphi_{traj}\left(L_v^{(\mathcal{L})}\right) \quad (8)$$

[0134] 公式(8)中，v^{future}为节点v的车辆轨迹预测结果，L_v为节点v的多线级特征，$\mathcal{L}$为图神经网络总层数，$L_v^{(\mathcal{L})}$为节点v的多线级特征L_v经过全部层图神经网络传递后得到的特征，$\varphi_{traj}(\cdot)$为循环神经网络解码器。

[0135] 如图2所示，为本实施例提供的车辆轨迹预测的整体架构示意图，图2中，首先分别构建子图，对车辆轨迹节点构建的图使用循环神经网络提取连续的车辆轨迹信息，对道路节点构建的图使用扩展图卷积神经网络提取复杂的道路信息，并额外保留一部分对车辆轨迹有间接性影响的其他信息，如人行横道，接着将所有带有信息的节点构建全局图，进一步通过图神经网络与自注意力机制获取特征，最后使用循环神经网络解码器对车辆的未来轨迹进行预测。

[0136] 本实施例提供的车辆轨迹预测方法，使用了一种新的地图交互，直接对原始地图进行矢量化来构建地图，能够避免信息丢失；利用扩展图卷积网络对特征矩阵和邻接矩阵进行卷积处理，能够捕获具有复杂拓扑结构的车道特征以及空间依赖关系，从而获取复杂

道路信息;使用多个邻接矩阵能够帮助我们摆脱图卷积网络只能捕获相邻节点信息的局限性,使得当前节点能够获得相邻多个节点的道路信息,完成扩展图卷积网络,提升道路空间信息获取能力;因为车辆轨迹信息是时间上连续的序列,因此利用循环神经网络捕捉车辆轨迹特征,以此获取车辆轨迹动态变化信息,结合复杂道路信息实现更高精度地预测;局部子图分别以扩展图卷积网络、循环神经网络以及矢量化地图的形式分类集成了车道图、车辆运行轨迹以及高精度地图的丰富信息,能够帮助模型完成更好的高阶交互,从而使得车辆轨迹预测方法具有更好的预测性能;构建层次化的图网络,将局部子图中由扩展图卷积网络和循环神经网络获取的特征信息传递到全局图,运用自注意力机制进行车道与车道、车道与车辆以及车辆与车辆的高阶交互,进而实现高准确度、高稳定度的轨迹预测。

[0137] 为验证本实施例提供的车辆轨迹预测方法的有益效果,通过经济效益计算和仿真实验进行以下科学论证。

[0138] 首先,针对本实施例提供的车辆轨迹预测方法,将平均位移误差ADE和最终位移误差FDE作为评价轨迹预测方法准确度的指标,ADE代表预测轨迹与实际轨迹之间的平均距离,FDE代表最终预测结果与实际真实位置的距离,将均方误差RMSE作为轨迹预测方法稳定性的指标,代表预测方法所预测结果的波动范围。ADE、FDE和RMSE的表达式分别如下式所示:

[0139]
$$\begin{cases} ADE = \dfrac{1}{N_q * T}\sum_{i=1}^{N_q}\sum_{t=1}^{T}\left|Y_{pred}^{t}[i] - Y^{t}[i]\right| \\ FDE = \dfrac{1}{N_q}\sum_{i=1}^{N_q}\left|Y_{pred}^{T}[i] - Y^{T}[i]\right| \\ RMSE = \sqrt{\dfrac{1}{\sigma}\sum_{t=1}^{\sigma}\left(Y_{pred}^{t} - Y^{t}\right)^2} \end{cases}$$

[0140] 其中,i为第i个预测对象,N_q为预测对象总数,t为预测时间样本t,T为预测总时长,$Y_{pred}^{t}[i]$、$Y^{t}[i]$为第i个预测对象在预测时间样本t的预测轨迹、实际轨迹,$Y_{pred}^{T}[i]$、$Y^{T}[i]$为第i个预测对象的最终预测结果、实际位置,σ为预测对象样本数量,Y_{pred}^{t}、Y^{t}为预测时间样本t的预测轨迹、实际轨迹。

[0141] 实验在具有Intel Core i7处理器、NVIDA GeForce RTX2070 SUPER显卡和16GB RAM的环境中运行,使用的操作系统是64位Windows10。

[0142] 实验数据所使用数据集包括Argoverse和NGSIM I-80;Argoverse中的数据来自Argo AI的自动驾驶测试车辆运行在迈阿密和匹兹堡区域的子集,这两个美国城市有不同的城市驾驶挑战和驾驶习惯。数据涵盖传感器数据的记录,和日志片段,包括不同季节、不同天气条件和一天中的不同时间,以提供广泛的现实世界驾驶场景。总车道长度覆盖迈阿密204公里,覆盖匹兹堡86公里;NGSIM I-80数据集为在2005年4月13日位于加州埃默里维尔的80号州际公路上收集和处理的数据,在完整的数据集中有总共45分钟的数据可用,分

为三个15分钟的时间段:16:00-16:15、17:00-17:15和17:15-17:30,包含详细的轨迹数据、广域探测器数据。该车辆轨迹数据每十分之一秒提供每辆车辆在研究区域内的精确位置,从而得到详细的车道位置和相对于其他车辆的位置。

[0143] 如图5所示,为本实施例提供的在Argoverse数据集上平均位移误差ADE和最终位移误差FDE的比较结果示意图,由图5可知,本实施例提供的车辆轨迹预测方法(本实施例中简称为GRA-MLN)相比于恒定速度法Constant Velocity、最近邻法Nearest Neighbor、基于长短期记忆网络的LSTM ED与uulm-mrm、基于向量化网络的VectorNet和基于图卷积神经网络的LaneGCN,在Argoverse数据集上平均位移误差ADE和最终位移误差FDE都有明显的降低,降低率分别为58.07%、57.10%、31.16%、22.11%、18.23%、13.45%和62.74%、62.69%、40.61%、29.83%、26.68%、22.22%,表明本实施例提供的车辆轨迹预测方法的实验结果预测精度相对较高。

[0144] 如图6所示,为本实施例提供的在NGSIM I-80数据集上均方根误差RMSE的比较结果示意图,图6中,不同颜色分别表示预测未来1秒、2秒、3秒、4秒和5秒的车辆轨迹时产生的均方误差,由图6可知,本实施例提供的车辆轨迹预测方法(本实施例中简称为GRA-MLN)相比于恒定速度法Constant Velocity、基于卡尔曼滤波的IMM-KF、机动分类与运动预测的统一框架C-VGMM+VIM、多步未来预测MFP-1、基于卷积社交池的长短期记忆网络CS-LSTM(M)和基于注意力机制的长短期记忆网络MHA-LSTM,在NGSIM I-80数据集上在τ秒内($\tau=1,2,3,4,5$)的未来轨迹预测RMSE指标分别有7.50%-50.00%、15.15%-52.54%、17.71%-53.85%、20.74%-55.32%和18.59%-53.37%的提升,与当前最好的基于图的信息共享网络GISNet模型非常接近,表明本实施例提供的车辆轨迹预测方法的预测结果误差相对较小,稳定性较高。

[0145] 由此可知,本实施例提供的车辆轨迹预测方法能够有效地降低车辆轨迹预测数据的平均位移误差ADE和最终位移误差FDE,并且能够有效减小均方误差RMSE,表明本实施例提供的车辆轨迹预测方法能够在保持稳定性的情况下,有效地提高车辆轨迹预测的精确度,进而达到较好的车辆轨迹预测效果。

[0146] 实施例二:

[0147] 本实施例提供一种车辆轨迹预测装置,包括:

[0148] 网络构建模块:用于构建矢量化地图,并利用矢量化地图,构建城市道路网络结构;

[0149] 信息捕获模块:用于根据城市道路网络结构,捕获复杂道路信息和连续的车辆轨迹信息;

[0150] 多线级特征计算模块:用于根据复杂道路信息和连续的车辆轨迹信息,计算获取多线级特征;

[0151] 全局图模型构建模块:用于根据多线级特征,构建全局图模型;

[0152] 预测模块:用于根据全局图模型,利用循环神经网络解码器对目标节点进行解码,获取车辆轨迹预测结果。

[0153] 本发明实施例所提供的车辆轨迹预测装置可执行本发明任意实施例所提供的车辆轨迹预测方法,具备执行方法相应的功能模块和有益效果。

[0154] 实施例三:

[0155] 本实施例提供一种系统，包括处理器及存储介质；

[0156] 存储介质用于存储指令；

[0157] 处理器用于根据指令进行操作以执行实施例一中方法的步骤。

[0158] 实施例四：

[0159] 本实施例提供一种计算机可读存储介质，其上存储有计算机程序，该程序被处理器执行时实现实施例一中方法的步骤。

[0160] 本领域内的技术人员应明白，本申请的实施例可提供为方法、系统、或计算机程序产品。因此，本申请可采用完全硬件实施例、完全软件实施例、或结合软件和硬件方面的实施例的形式。而且，本申请可采用在一个或多个其中包含有计算机可用程序代码的计算机可用存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。

[0161] 本申请是参照根据本申请实施例的方法、设备(系统)、和计算机程序产品的流程图和/或方框图来描述的。应理解可由计算机程序指令实现流程图和/或方框图中的每一流程和/或方框、以及流程图和/或方框图中的流程和/或方框的结合。可提供这些计算机程序指令到通用计算机、专用计算机、嵌入式处理机或其他可编程数据处理设备的处理器以产生一个机器，使得通过计算机或其他可编程数据处理设备的处理器执行的指令产生用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的装置。

[0162] 这些计算机程序指令也可存储在能引导计算机或其他可编程数据处理设备以特定方式工作的计算机可读存储器中，使得存储在该计算机可读存储器中的指令产生包括指令装置的制造品，该指令装置实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能。

[0163] 这些计算机程序指令也可装载到计算机或其他可编程数据处理设备上，使得在计算机或其他可编程设备上执行一系列操作步骤以产生计算机实现的处理，从而在计算机或其他可编程设备上执行的指令提供用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的步骤。

[0164] 以上仅是本发明的优选实施方式，应当指出，对于本技术领域的普通技术人员来说，在不脱离本发明技术原理的前提下，还可以做出若干改进和变形，这些改进和变形也应视为本发明的保护范围。

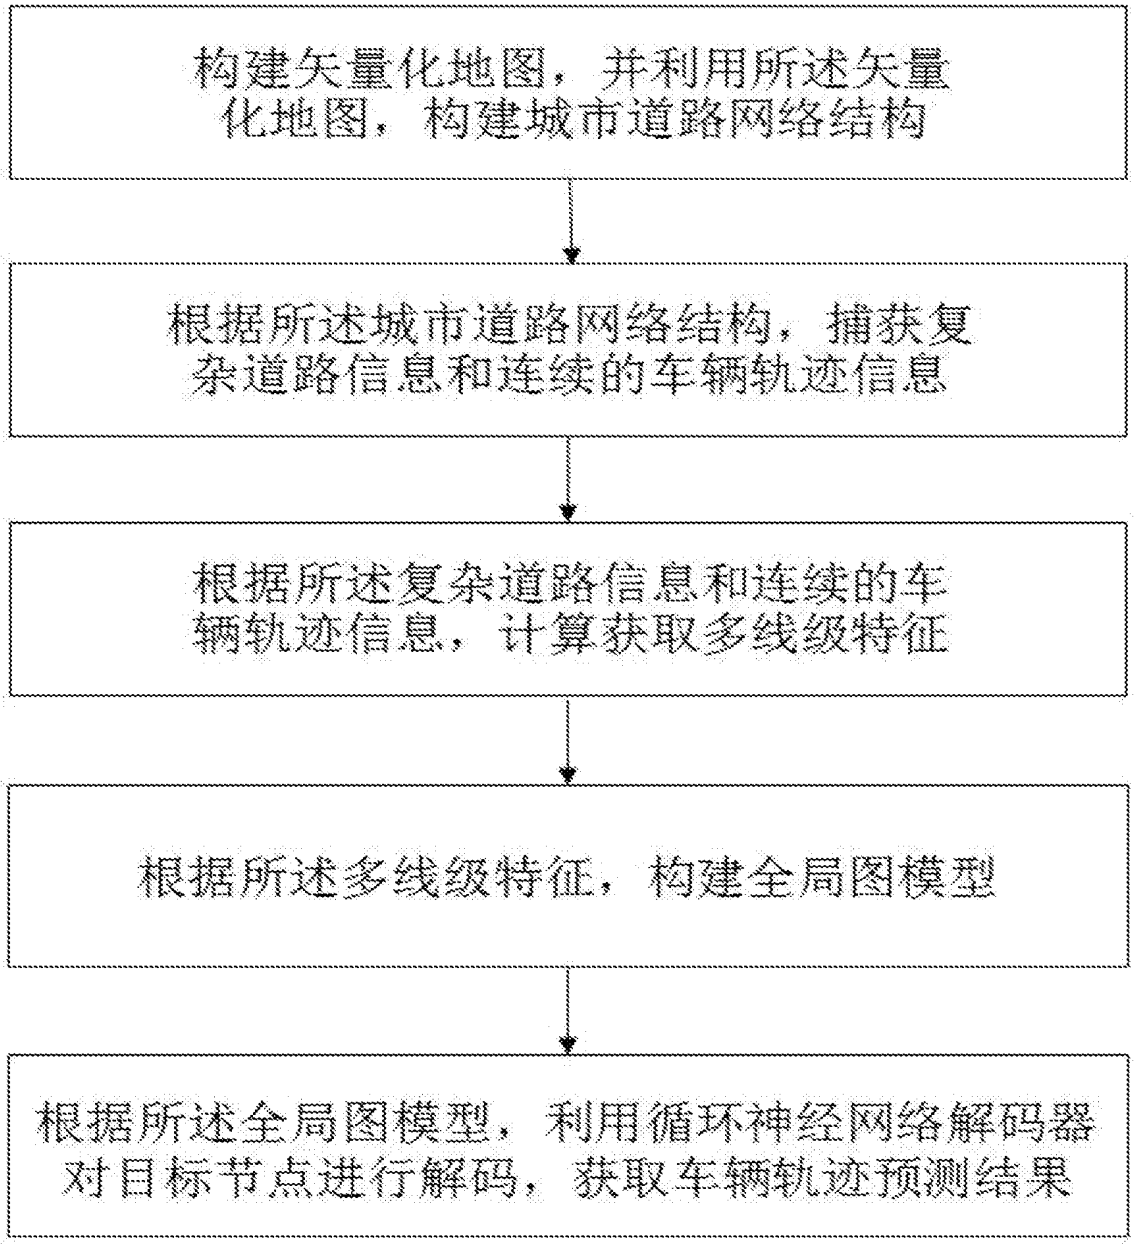

构建矢量化地图，并利用所述矢量化地图，构建城市道路网络结构
根据所述城市道路网络结构，捕获复杂道路信息和连续的车辆轨迹信息
根据所述复杂道路信息和连续的车辆轨迹信息，计算获取多线级特征
根据所述多线级特征，构建全局图模型
根据所述全局图模型，利用循环神经网络解码器对目标节点进行解码，获取车辆轨迹预测结果

图1

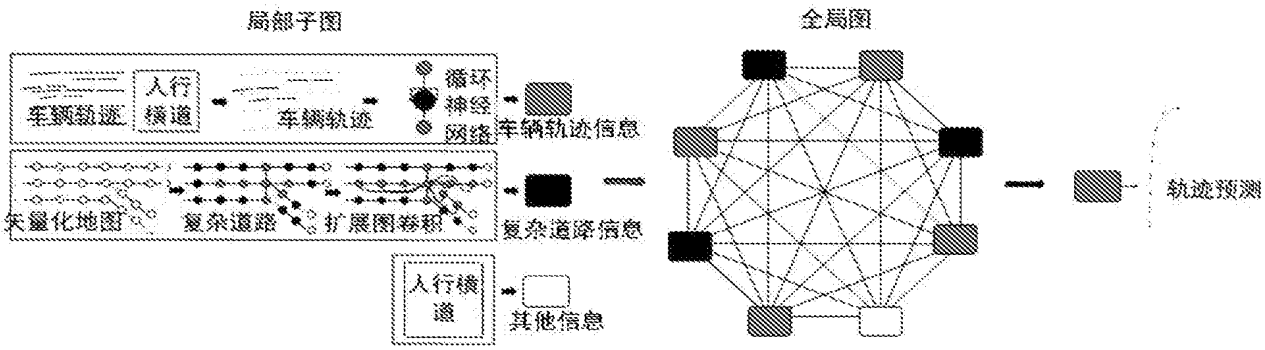

局部子图
全局图
车辆轨迹
人行横道
车辆轨迹
循环神经网络
车辆轨迹信息
矢量化地图
复杂道路
扩展图卷积
复杂道路信息
人行横道
其他信息
轨迹预测

图2

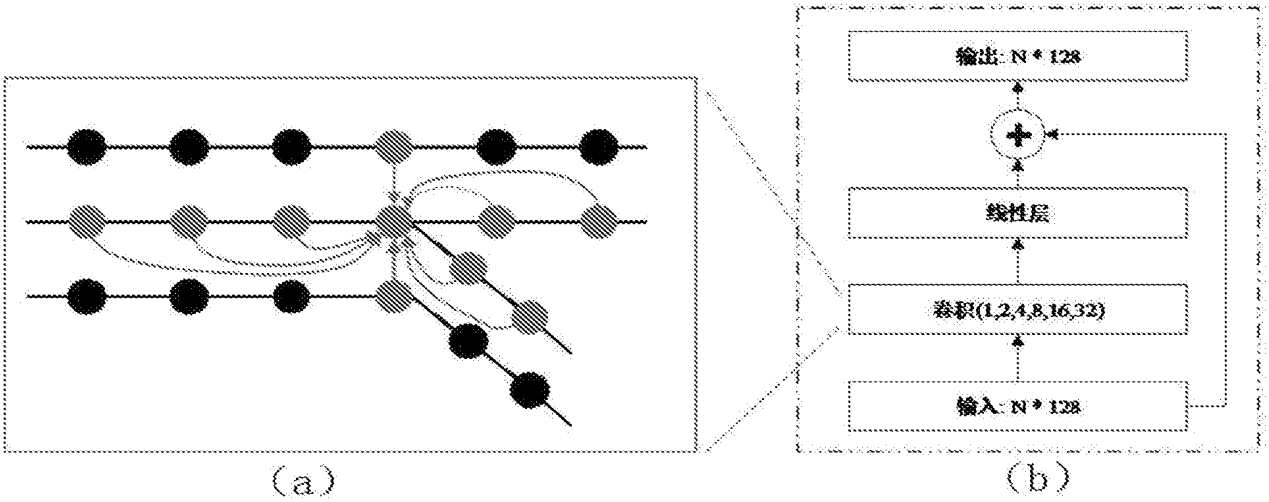

输出: N * 128
线性层
卷积(1,2,4,8,16,32)
输入: N * 128
(a)
(b)

图3

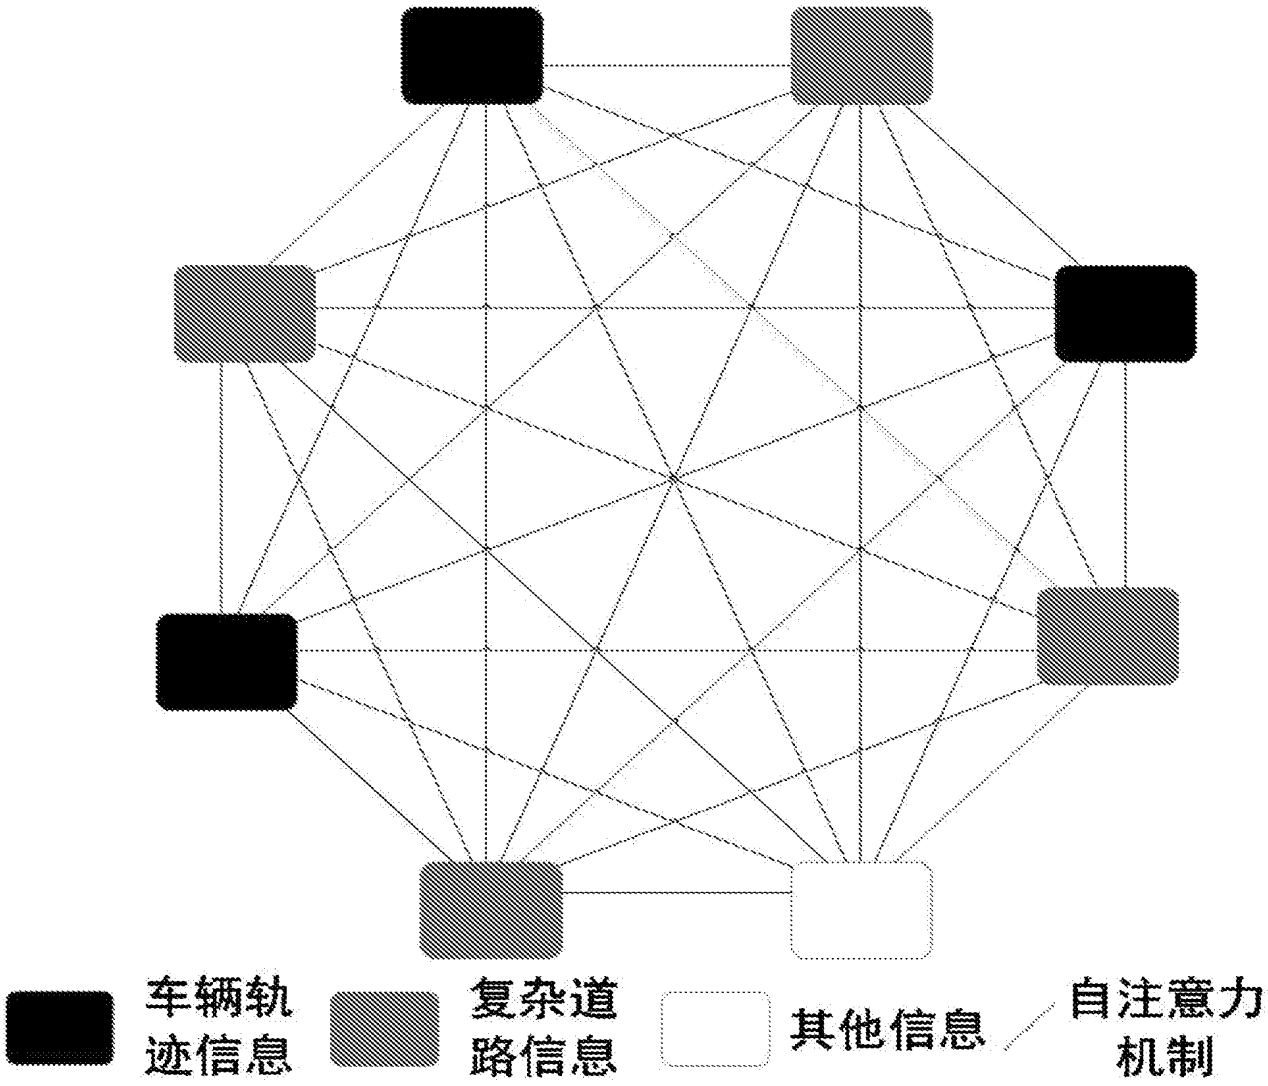


图4

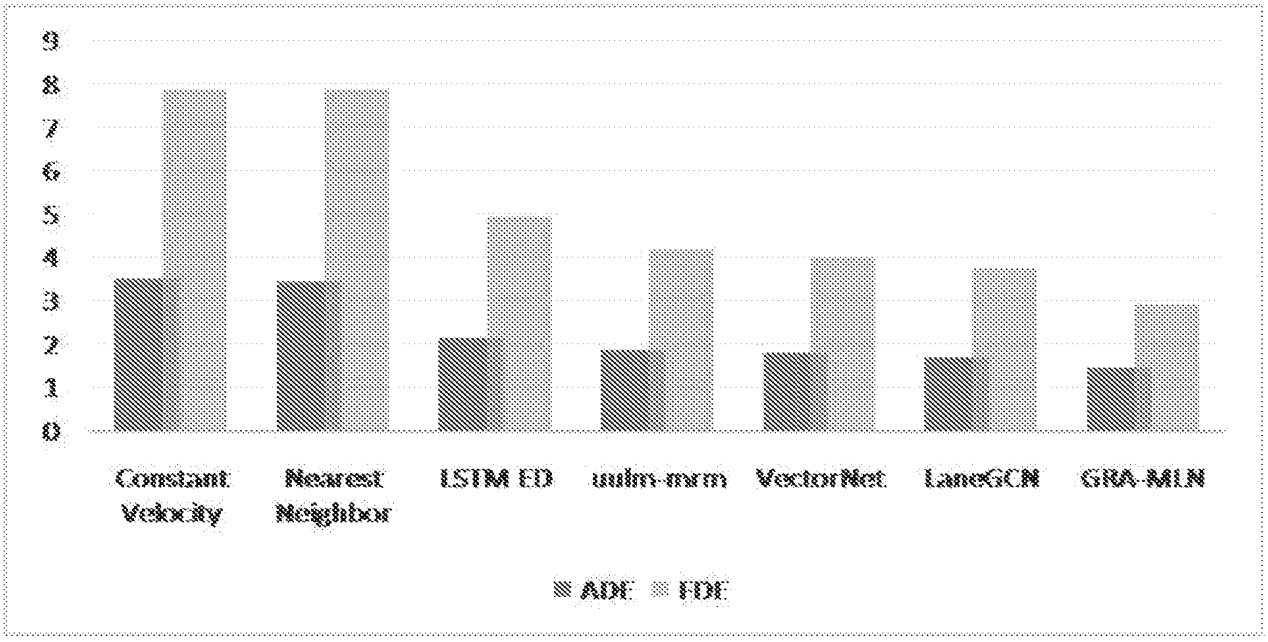

9
8
7
6
5
4
3
2
1
0
Constant Velocity
Nearest Neighbor
LSTM ED
uulm-mrm
VectorNet
LaneGCN
GRA-MLN
ADE
FDE

图5

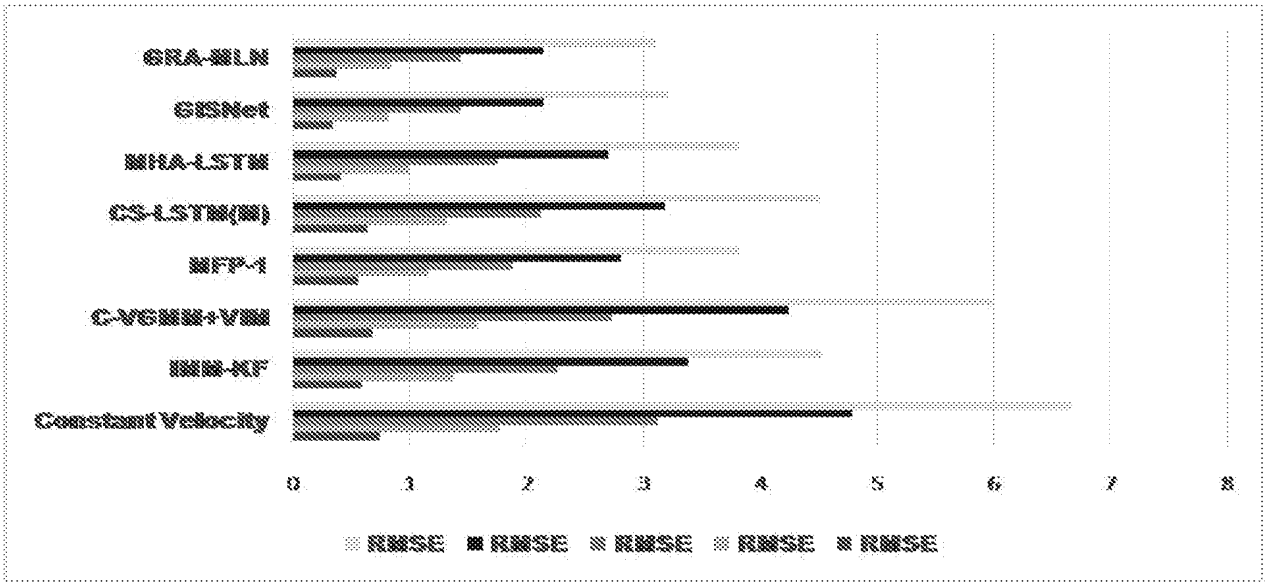

GRA-MLN
GISNet
MHA-LSTM
CS-LSTM(M)
MFP-1
C-VGMM+VIM
IMM-KF
Constant Velocity
0
1
2
3
4
5
6
7
8
RMSE
RMSE
RMSE
RMSE
RMSE

图6